Development Minimalist of the Llama2 Model

Github: https://github.com/Linhcodelinhtinh/ASM1-Development-LLM-model

Nhóm JQKA. Thành viên: Nguyễn Đình Khải, Nguyễn Thế Khôi, Võ Duy Quang, Lưu Quang Linh.

1. Results & Analysis

Text Generation

Với tác vụ sinh văn bản, nhìn chung là mô hình pretrained trên TinyStories có thể tạo ra tiếng Anh tương đối trôi chảy, dù nội dung đôi khi khá đơn giản hoặc ngây ngô:

- temperature = 0: câu sinh ra mạch lạc hơn, ít đa dạng hơn, thường ổn định và coherent hơn.
- temperature = 1: output ngẫu nhiên hơn, đa dạng hơn nhưng cũng mất tính logic tương đối.

Zero-shot Prompting

Kết quả zero-shot prompting:

Dataset	Dev	Test
SST	0.213	0.224
CFIMDB	0.502	0.213

Kết quả zero-shot khá thấp và gần mức ngẫu nhiên. Điều này hợp lý vì mô hình pretrained không được train trực tiếp cho sentiment classification và có một sự domain shift nhẹ.

Finetuning

Trên tập SST:

Đặc tính	Seed 1 (Default)	Seed 1	Seed
Epoch	5	5	5
LR	2e-5	2e-5	2e-5
Batch size	80	90	32
Drop out	None	None	0.1
Dev	0.425	0.421	0.437
Test	0.398	0.427	0.434

Trên tập CFIMDB:

Đặc tính	Default	Seed 1	Seed 1	Seed 2	Seed 3	Seed 3	Seed 4
Epoch	5	5	8	15	6	6	6
Drop out	None	None	None	0.2	0.5	0.3	0.5
LR	2e-5	2e-5	2e-5	2e-5	2e-5	2e-5	2e-5
Batch size	10	16	16	16	8	8	8
Dev	0.857	0.857	0.869	0.882	0.747	0.894	0.902
Test	0.469	0.506	0.529	0.559	0.752	0.551	0.508

Tham số được tune bằng tay và cả grid search.

Kết quả cho thấy finetuning hiệu quả hơn rõ rệt so với zero-shot prompting. Nguyên nhân chính là trong finetuning, classifier head được học trực tiếp từ dữ liệu có nhãn, cũng như mô hình học được ánh xạ từ representation của câu sang label cụ thể, thay vì chỉ dựa vào khả năng ngôn ngữ chung của pretrained model.

Zero-shot có kết quả thấp vì một số lý do:

- Mô hình pretrained trên TinyStories, nên có domain mismatch lớn với review sentiment.
- Kích thước mô hình nhỏ hơn nhiều so với các LLM hiện đại.

- Prompt-based classification đòi hỏi năng lực instruction-following tốt, trong khi mô hình này không được tối ưu riêng cho kiểu sử dụng đó.

Review của CFIMDB cho cảm giác khó hơn về mặt semantic, review dài , phức tạp , chứa nhiều ẩn ý và từ vựng đa dạng. Trong khi đó SST ngắn hơn và thường trực tiếp hơn về mặt cảm xúc, nên phù hợp hơn với mô hình nhỏ. SST lại có tới 5 label thay vì 2 label như CFIMDB. Tập test của CFIMDB chỉ bao gồm các mẫu data có label là 0 nên việc kết quả chênh lệch giữa tập dev và tập test là bình thường.

2. Improvements

Drop out

Bổ sung tham số drop out cho backbone llama. Kết quả đã được trình bày ở trên. Thêm drop out giúp mô hình tổng quát hơn

Few-shot Prompting

Nhóm thử nghiệm few-shot prompting trên model gốc chưa finetune để xem mức cải thiện của model khi được cung cấp prompt chi tiết. Cụ thể, nhóm xây dựng một hàm build_prompt_template hoạt động khi lệnh chạy có flag "few_shot":

```
def build_prompt_template(label_names: list[str], few_shot: bool = False) -> tuple[Optiona
l[str], str]:
    #...
    for review, label in examples:
        prompt_parts.append(f"Review: {review}\nSentiment: {label}\n\n")
    prompt_prefix = "".join(prompt_parts) + "Review: "
    return prompt_prefix, "\nSentiment:"
```

Trong đó, phần có label_set nhị phân bad - good là examples khi chạy trên tập data *cfimdb*, còn phần examples với 5 mẫu tương ứng 5 label là few-shot prompting dành cho tập *stt*.

Kết quả few-shot prompting:

Dataset	Dev	Test
SST	0.256	0.245
CFIMDB	0.465	0.301

Kết quả few-shot có cải thiện nhẹ, tăng từ 2-8% accuracy so với zero-shot prompting. Cải thiện này là đáng kể và hợp lý vì mô hình pretrained không được train trực tiếp cho sentiment classification.

3.. How to Run

Chạy file `run_llama.py` với các chế độ `--generate --prompt -- finetune` như bình thường

Few-shot prompting

Thêm flag few_shot:

`python run_llama.py --option prompt --train data/cfimdb-train.txt ... --few_shot`

Drop out

`python run_llama.py --option finetune --epochs 15 ... --llama_dropout 0.1`

4. Issues and Debugging Notes

RoPE bug

Đây là lỗi khó nhất. Ban đầu implementation RoPE không khớp với sanity_check.data, dù ý tưởng tổng thể đúng. Vấn đề nằm ở cách xoay vector và khôi phục shape do chúng em thực hiện tách số phức thành phần thực - phần ảo và xử lý các phép quay, broadcast,... thủ công . Sau khi kiểm tra lại, chúng em chuyển sang hiện thực bằng complex numbers để phép quay rõ ràng hơn và kết quả đã khớp với sanity_check.

Encoding issues on Windows

Khi đọc và ghi dữ liệu trên Windows, một số file gây lỗi UnicodeDecodeError /UnicodeEncodeError do encoding mặc định cp1252. Nhóm sửa bằng cách chỉ định encoding='utf-8' khi mở file.

Cùng một vài vấn đề nhỏ khác liên quan đến checkpoint loading và saving trên Windows trong quá trình finetuning.